

# 社會網路的好友推薦

林苡辰  
資訊管理所  
成功大學  
台南, 台灣

r76114026@gs.ncku.edu.tw

**Abstract**—圖神經網路(GNN)最近在圖學習方面取得了實質性的進展，本篇報告將根據圖神經網路的應用，以及 Graph Neural Networks for Friend Ranking(GrafRank)的模型進行修改，目的為設計出一推薦系統，能針對社會網路的資料集進行中心使用者的潛在好友推薦，並達到有效提升推薦準確率之成果。

**Keywords**—Graph Neural Network, Social Network, Recommendation System

## I. 緒論

### A. 研究背景與動機

學習潛在用戶表示在提高用戶理解方面變得越來越重要，並在各種商業環境中得到廣泛採用，例如：Youtube 上的影片推薦、Printest 上的 pin 建議等。使用深度學習模型學習的用戶表示在以下方面能有效補充或替代傳統的協同過濾方法並且用途廣泛，例如：嵌入可用於朋友推薦，還可以推斷社交網路中的個人資料屬性（例如：年齡、性別）(Sankar et al., 2021)。

圖神經網路(GNN)已經成為一種流行的圖表示學習範例，因為它們能夠學習結合圖結構和節點/鏈接屬性的表示，不需要依賴昂貴的特徵擷取工程，而學習圖中節點的潛在表示在多種學術環境中具有突出的應用。GNN 可以製定為消息傳遞框架，其中通過可訓練的鄰居聚合器從本地的圖鄰域傳播特徵來學習節點表示。並且最近 GNN 在一些設計用於二分或多分用戶到項目交互圖中的項目推薦的工業系統中展示了有希望的結果(Sankar et al., 2021)。

儘管具有豐富的表示能力，但 GNN 在大規模用戶-用戶社交建模應用程序（如朋友建議）中的探索相對較少。推薦新的潛在朋友以鼓勵用戶擴展他們的網絡，是社交網絡的基礎，對用戶保留和促進平台內的參與度起著重要作用。

根據目前 GNN 在大規模用戶的發展現況主要面臨兩大困難。首先，社會網絡的特點是重尾分佈，這對相當一部分朋友很少的用戶來說，在訊息有限的情況下做用戶好友推薦是一個關鍵挑戰；其次，現代社交平台為用戶提供了多種互動方式，例如，用戶可以通過直接交換消息和圖片，或透過按讚和評論貼文等間接社交活動與朋友交流。從這種異構的平台內用戶操作中提取知識具有挑戰性，但對於解決絕大多數不活躍用戶的稀疏性挑戰非常有價值。

而 Sankar et al. (2021)等學者提出了 Graph Neural Networks for Friend Ranking(GrafRank)模型，有效解決上

述問題，但此模型為針對 Snapchat 平台的用戶做潛在朋友推薦，以下將針對與改善方向進行描述。

### B. 問題描述

本篇報告將針對 GrafRank 模型下去做修改並達到推薦用戶潛在好友的成果，欲改善問題如下：

- 1) 資料的數據稀疏性：本篇報告使用的資料集不符合數據稀疏的特性，將會對資料進行欲處理。
- 2) 模型的平台適應性：GrafRank 模型為針對 Snapchat 平台做的推薦模型，該如何對模型做改善達到對 Facebook 平台的用戶做推薦為一挑戰。
- 3) 嵌入：GrafRank 模型的用戶特徵嵌入與本此實驗與使用的特徵嵌入屬性不同，該如何做調整以達到合適的成效為本篇報告的目標之一。

### C. 預期貢獻

根據上節描述之問題，本篇報告預期有以下貢獻：

- 1) 針對 GrafRank 模型做改善，設計出一新的模型能符合 Facebook 資料集的潛在用戶推薦。
- 2) 觀察 GrafRank 模型在不同平台之推薦成效。
- 3) 觀察不同深度學習模型應用在大型社會網絡之推薦成效。

## II. 文獻探討

### A. Friend Recommendation Systems

最早的好友推薦方法是設計基於圖形的社交網路中用戶與用戶接近度的啟發式方法(Liben-Nowell & Kleinberg, 2003)。

Ma et al. (2008)等學者提出了一種使用概率矩陣分解的社交推薦算法，該算法結合社交關係矩陣和用戶-項目交互矩陣，通過特徵共享挖掘用戶社交關係對目標用戶的影響。Yang et al. (2017)等學者將用戶信任網絡分為信任行為和被信任行為，通過融合用戶與物品之間的交互信息和用戶之間的信任網絡進行混合推薦，提高推薦性能。Liu et al. (2020)等學者採用信息傳播的方法劃分多關係社交網絡的社區結構，並結合協同過濾算法進行推薦。上述方法實驗了用戶與物品之間的推薦任務。

最近，圖嵌入方法學習潛在節點表示已得到節點及其臨域的結構屬性，廣泛使用的嵌入模型如：node2vec 和 deepwalk，學習無監督嵌入以最大化在固定長度中隨機遊走的共同可能性，並顯示出有效的網路節點連線預測性能(Sankar et al., 2021)。

而一個與節點連線預測相關的方向是社交推薦，它利用社交網絡作為輔助數據源來模擬社交平台中的用戶行

為並提高向用戶推薦項目的質量(Sankar et al., 2021)。相比之下，本篇報告欲解決的問題—朋友推薦，是一個用戶-用戶推薦任務，有助於創建更好的用戶社交網路並且作為社交網路推薦的補充，有利於對社交好友推薦。

### B. Recommendations Integrating Attention Mechanism

Yu et al. (2019)在對用戶的短期偏好進行建模時引入了一種注意力機制來過濾用戶行為序列，並基於注意力框架自適應地融合了用戶的長期和短期偏好。Peng et al. (2019)提出了一種混合模型 HARSAM，將注意力機制與深度神經網絡相結合，利用自注意力機制提取不同時間間隔物件之間的相關性。Yi et al. (2023)提出了一種基於注意力門控循環單元的算法，考慮到用戶對項目的偏好的動態變化。

Yi et al. (2023)使用用戶交互數據構建多模態交互圖，並引入基於 GNN 的門控注意力機制來區分不同模態對用戶偏好的重要性，從而捕獲隱藏信息並提供更準確的推薦。

根據前段提到的經驗，本次報告將著重一跨模態注意力機制，以學習不同特徵模態之間複雜的非線性相關性。

### C. Multi-Relational Graph

基於網絡結構的最大保留，Huang et al. (2016)通過從每個網絡中選擇重要特徵來對齊相關網絡，使用標籤和聯繫網絡。這種方法忽略了一些重要的特徵，沒有考慮到網絡結構的特點，只適用於單一網絡。

多圖關係在多個領域上都有研究，Chen et al. (2020)提出了側重於網絡的特徵結構的方法，同時關注社會圖的結構特徵，設計了大多數類型圖的端到端適配的學習方法，適用於多種類型的網絡。

本篇報告也會應用到多圖關係概念，將設計一模型能包含多群體的特徵結構，進而進行好友任務推薦。多社交圖概念如圖 II-1，呈現了一社會圖中，包含了多個社交關係。

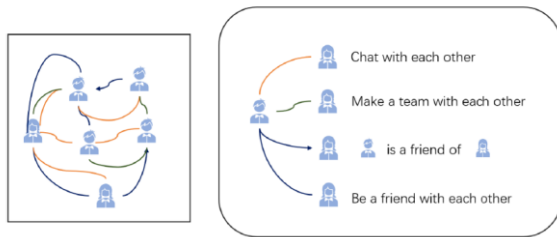


圖 II-1 社會圖之多個社交關係

### D. Graph Representation

從生物蛋白質結構的研究到基於社會關係的好友推薦，圖數據中的學習任務涉及廣泛且具高度需求。圖數據學習的關鍵在於如何學習拓撲資訊並將其轉化為現有機器學習模型的表示向量。近年來在大量需求的刺激下，圖學習方法發展快速，使得從學習拓撲到學習低維特徵逐漸被拿來應用以及討論(Chen et al., 2020)。

圖的向量表示可以分為三種方法：基於矩陣的方法、基於隨機遊走的方法如：DeepWalk、LINE、Node2vec 和基於圖神經網絡 (GNN) 的方法(Chen et al., 2020)。本篇報告將著重於 GNN 的發展應用進行模型的改良。

### E. Graph Neural Networks(GNN)

GNN 的研究與圖嵌入或網絡嵌入密切相關，這是另一個引起數據挖掘和機器學習越來越多關注的話題。網絡嵌入旨在將網絡節點表示為低維向量表示，同時保留網絡拓撲結構和節點內容信息，以便可以使用簡單的現成方法輕鬆執行任何後續圖形分析任務，如分類、聚類和推薦機器學習算法。同時，GNN 是深度學習模型，旨在以端到端的方式解決與圖相關的任務(Wu et al., 2020)。

GNN 通過使用聚合和激活函數從局部鄰域遞迴傳播特徵（即消息傳遞）來學習節點表示，而其對於大規模用戶-用戶社交建模應用程序仍未得到充分探索，在這些應用程序中，用戶通過與社交平台上的不同功能進行交互來表現出多方面的行為(Sankar et al., 2021)。

GNN 和網絡嵌入之間的主要區別在於，GNN 是一組為各種任務設計的神經網絡模型，而網絡嵌入涵蓋了針對同一任務的各種方法。因此，GNN 可以通過圖形自動編碼器框架解決網絡嵌入問題。另一方面，網絡嵌入包含其他非深度學習方法，例如矩陣分解和隨機遊走(Wu et al., 2020)。

在本次報告，預期透過具有用戶特徵和連結通信特徵的多方面好友排名公式，進行 GNN 的設計，進而應用於社會網路好友建議。

### F. Graph Convolution Network (GCN)

GNN 的出現擴展了神經網絡來處理圖數據，受 CNN 在許多任務中的優異表現的啟發，GCN 通過半監督學習學習全卷積信息；GraphSAGE 通過採樣子圖聚合鄰居來學習節點表示(Chen et al., 2020)。

GCN 最初是為圖分類任務設計的，並配備了許多神經網絡操作，其用於學習高階鄰居的資訊並將其融合到用戶的節點特徵中，從而基於貝葉斯個性化推薦原理構建好友推薦系統(He et al., 2020)。

Chen et al. (2020)提出 Multi-Social Graph Convolutional Network(MSGCN) 專注於解決集成多個圖形數據以學習用戶表示的問題，使用了多種關係來增強對用戶特徵的學習。

### G. Light Graph Neural Networks(LightGCN)

GCN 中最常見的兩種設計—特徵轉換和非線性激活，對協同過濾的性能貢獻很小，並且它們會增加訓練的難度並降低推薦性能。為了簡化 GCN 的設計，使其更簡潔、更適合推薦，He et al. (2020)等學者提出了 LightGCN，其模型僅包括 GCN 中最重要的部分—鄰域聚合，用於協同過濾。

具體來說，LightGCN 通過在用戶-項目交互圖上線性傳播用戶和項目嵌入來學習它們，並使用在所有層學習的嵌入的加權和作為最終嵌入。

根據 LightGCN 的設計，考慮到本次報告模型方法為圖任務的探討，並對使用者特徵進行處理、獲得嵌入，進而計算最終好友分數，故最後會將 LightGCN 加入基準模型，進而比較其差異。

## III. 研究目的

本篇報告將針對 Sankar et al. (2021)等學者提出的 GraFRank 模型進行修改，在 GraFRank 模型中，通過具




圖 III-1 帶有標記圓圈的中心節點網絡

有多模態用戶特徵和鏈接通信特徵的新穎的多方面好友排名公式，為好友建議的重要應用設計 GNN，並且對非線性交叉模態相關性進行建模以學習多方面的用戶表示。

Sankar et al. (2021)通過利用異構平台內動作的豐富知識來克服結構和交互稀疏性。並將社交網絡上的朋友推薦制定為不斷發展的友誼圖上的多方面朋友排名，具有多模態用戶特徵和鏈接通信特徵。

然而此方法所針對為單一平台(Snapchat)上的方法，本次報告與針對特徵上做模型的改善，期望能將 GraFRank 模型應用於 Facebook 好友網絡的社交平台上進行好友推薦。

#### A. 問題定義

在本節中，將介紹社交平台中與好友推薦相關的不同訊息來源。平台中的每個人都由一個用戶  $u$  或  $v$  表示，一對用戶  $(u, v)$  可以通過友誼連接，為一種無向關係，即  $u$  若為  $v$  的朋友，則  $v$  也是  $u$  的朋友。在此假設一組用戶  $V$  在我們對平台的最新觀察時間之前引入。當新的友誼形成和新用戶加入平台時，友誼圖  $G$  會發生變化。以下將定義帶有標記圓圈的中心網絡(如圖 III-1)：

我們有一個用戶  $u$ ，並且在他的朋友  $v_i$  之間形成了一個網絡。然後將用戶  $u$  稱為中心，將節點  $v_i$  稱為改變者。接下來的任務是識別每個 alter  $v_i$  所屬的圈子，如圖 III-1 所示。換句話說，目標是在給定的自我網絡中找到嵌套和重疊的社區/集群。

因此我們定義朋友推薦排名問題如下：

給定圖  $G(u, v)$ 、節點特徵  $X$  和邊特徵  $E$ ，設計一個模型來預測每個 ego  $u \in G$  的好友親和力得分  $Suv$ 。

#### B. 目的和目標

- 期望能將 GraFRank 此多圖模型應用在不只是 Snapchat 此平台上，能將此模型應用於 Facebook 的社交網路中進行好友推薦。
- 原參考模型有解決數據稀疏性問題，期望在 Facebook 平台也能解決數據稀疏性，進而做到有效的好友推薦。
- 改善模型方法，將原模型的三維度特徵向量調整為符合 Facebook 平台資料特徵的向量維度，進行 concat，並設計一預測模型，達到有效的好友社群平台推薦。

- 利用類神經方法，將 Facebook 平台之特徵向量數據轉換為三維之狀態以符合模型特徵，進而進行好友推薦。
- 比較上述第三、第四點之設計效果差異。
- 比較改善之模型與原模型以及相應常見之模型效能上的差異。

### IV. 研究方法

在本節中，首先介紹用於好友排名的模型 GraFRank (Graph Attention Friend Ranker) 的關鍵組件。我們在設計多模式 GNN 時的建模選擇直接來自我們的觀察。

GraFRank 有兩個模塊(如圖 IV-1)：

- 模態特定的鄰居聚合
- 跨模態注意層

下面，將針對每個模塊進行詳細說明。

#### A. 模態特定的鄰居聚合

由於不同模態在誘導同質性的程度上有所不同，我們單獨對待每種模態，而不是通過串聯組合所有特徵的主流選擇。因此，我們在群組  $t \in \mathbb{R}^+$  為每個用戶  $u \in V$  學習了特定於模態的表示  $z_u^k(t) \in \mathbb{R}^D$ ，它封裝了來自模態  $k$  的信息。每個用戶  $u$  靈活地優先考慮他的群組鄰域  $N_t(u)$  中的不同朋友，從而解釋跨用戶群的同質分佈差異。

我們設計了一個模態特定的鄰居聚合模塊來計算  $K$  表示  $\{z_u^1(t), \dots, z_u^K(t)\}$ ， $z_u^k(t) \in \mathbb{R}^D$  對於每個用戶  $u \in V$  在群組  $t \in \mathbb{R}^+$ ，其中每個  $z_u^k(t)$  是使用每個模態的獨立且唯一的消息傳遞函數獲得的。

我們首先描述一個單層，它由兩個主要操作組成：消息傳播和消息聚合。後續將討論對多個連續層的泛化。

##### 1) 消息傳播

我們定義了消息傳遞機制，以在群組  $t$  聚合來自用戶  $u$  的自我網絡  $N_t(u)$  的信息。具體來說，模態  $k$  的傳播步驟從群組鄰居  $N_t(u)$  的相應快照  $s = \tau(t)$  聚合第  $k$  模態特徵  $\{x_v^{s,k} : v \in N_t(u), s = \tau(t)\}$ 。

為了量化中心網絡中每個朋友  $v$  的重要性，我們提出了一種友誼關注(Sankar et al., 2021)。它將嵌入  $x_u^{s,k}$  和  $x_v^{s,k}$  作為輸入，併計算注意力係數  $\alpha^k(u, v, t)$  控制朋友  $v$  在群組  $t$  對用戶  $u$  的影響，公式如下：

$$\alpha^k(u, v, t) = \text{LeakyRELU} \left( a_1^T (W_1^k x_u^{s,k} || W_1^k x_v^{s,k}) \right) \quad (1)$$

$$s = \tau(t) \quad (2)$$



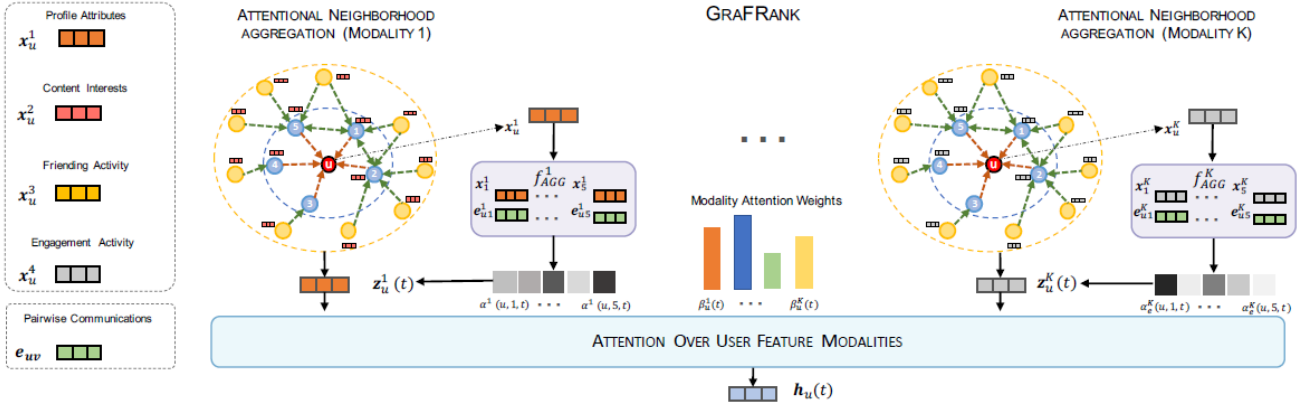


圖 IV-1 GraFRANK

其中， $W_1^k \in R^{D_k \times D}$  是應用於每個用戶的共享線性變換， $||$  是串聯操作， $a_k \in R^{2D}$  友誼注意力被建模為單個前饋層參數化權重向量跟非線性 LeakyReLU。

然後通過採用 softmax 函數對在群組  $t$  與  $u$  連接的所有朋友的注意力係數進行正歸化，公式如下：

$$\alpha^k(u, v, t) = \frac{\exp(\alpha^k(u, v, t))}{\sum_{w \in N_t(u)} \exp(\alpha^k(u, w, t))} \quad (3)$$

## 2) 消息聚合

我們通過聚合從  $N_u(t)$  中的朋友傳播的消息來改進用戶  $u$  的表示。此外，我們考慮自連接  $m_{u \leftarrow u}^k = W_1^k x_u^{s,k}$  以保留原始特徵的知識 ( $W_1$  與等式 1 中使用的變換相同)。

具體來說，我們連接用戶  $u$  的中心網絡和中心節點表示，並通過密集層  $F_\theta^k$  進一步轉換連接的嵌入，公式定義如下：

$$z_u^k(t) = F_\theta^k(m_{u \leftarrow u}^k, z_u^k(t, N_u(t))) \quad (4)$$

## B. 跨模態注意力層

為了學習不同特徵模態之間複雜的非線性相關性，我們設計了一種跨模態注意力機制。具體來說，我們使用雙層多層感知器學習模態注意力權重  $\beta_u^k(t)$  來區分每個模態  $k$  的影響，公式定義如下：

$$\beta_u^k(t) = \frac{\exp(a_m^T W_m z_{u,L}^k + b_m)}{\sum_{k'=1}^K \exp(a_m^T W_m z_{u,L}^{k'} + b_m)} \quad (5)$$

其中，權重  $W_m \in R^{D \times D}$ ， $a_m \in R^D$ ， $b_m$  為標量偏差。

使用者  $u$  的最終表示  $h_u(t) \in R^D$  是通過  $L$  層模態特定用戶表示  $\{z_{u,L}^1, \dots, z_{u,L}^K\}$  的加權聚合計算的，由模態權重  $\beta_u^k(t)$  引導，公式定義為：

$$h_u(t) = \sum_{k=1}^K \beta_u^k(t) W_m z_{u,L}^k \quad (6)$$

## V. 實驗

為了分析修改後的 GraFRANK 模型學習到的用戶表示的質量以及預測成效，故提出了三個研究問題來執行實驗：

**RQ1** 修改後的 GraFRANK 模型成效上是否與原參考論文之 GraFRANK 模型具有等同或更好的預測成效？

**RQ2** 修改模型中特徵向量維度和修改預測函式，兩者在推薦成效上的差異？

**RQ3** 本篇報告提出之模型方法與基準方法（例如：LightGCN）之效果差異？

## A. 資料來源

為了評估修改後的 GraFRANK 模型，我在這次實驗中使用 Stanford Network Analysis Project (SNAP) 提供的 Facebook 資料集。

該數據集由來自 Facebook 的“朋友圈”（或“好友列表”）組成。Facebook 數據是從使用此 Facebook 應用程式，參與研究調查者那裡收集而得。數據集包括節點特徵（配置文件）、交友網路和中心節點網路（如表 IV-1）。Facebook 數據已透過使用新值替換每個用戶的 Facebook 內部 ID 進行匿名處理。

此外，雖然提供了來自該數據集的特徵向量，但對這些特徵的解釋卻很模糊。例如，在原始數據集可能包含特徵“政治=民主黨”的情況下，新數據將只包含“政治=匿名特徵 1”。因此，使用匿名數據可以確定兩個用戶是否具有相同的政治派別，但不能確定他們個人的政治派別代表什麼。

而為了符合本次實驗一開始之設計—解決數據稀疏性的問題，雖然數據集提供之中心節點網路包含 10 個，為了使數據集具有數據稀疏，將選擇 2 至 3 個中心節點網路進行實驗，不會使用到全部的網路。

## B. 評估指標

為了評估好友推薦，本次報告的評估指標和參考論文相同，使用排名指標命中率 (HR@K)、正規化折扣累積增益 (NDCG@K) 和平均倒數排名 (MRR)。其中，採用負樣本評估為測試集中的每個正對  $(u, v)$  生成  $N$  負樣本（用戶  $u$  已向用戶  $v$  發送好友請求）。然後，通過潛在空間

表 IV-1 數據集統計

Dataset	Facebook
Users	4039
Links	88234
User features	224
Link features	5385
networks	10
Ego users	10

表 V-1 實驗結果

Dataset	Facebook				
Metrics	N@5	N@10	HR@5	HR@10	MRR
GraFRank	0.2684	0.3098	0.3772	0.5051	0.2669
LightGCN					
My model (adjusted)					

中的內積對 $N$ 負樣本中的 $v$ 進行排名，從而評估每個測試對 $(u, v)$ 的指標。

### C. 評估基準

實驗將本篇報告修改之模型與原參考論文一朋友排名的 GraFRank 進行比較。另外，與基於強大特徵的排名模型和最先進的 GNN 模型進行比較。

- GraFRank: 此模型是一種基於圖神經網路架構，用於解決排序和排名問題。透過建模對象之間的關係和利用圖神經網路的學習表示能力來實現更好的排序性能，進而做更好的好友推薦 (Sankar et al., 2021)。
- LightGCN: 此模型是一種簡化的圖卷積網路模型，用於推薦系統。其透過簡化的訊息傳播策略和簡單的參數更新方式，提供了高效和可拓展之推薦模型 (He et al., 2020)。

### D. 參數設置

實驗使用  $L = 2$  每個模態的消息傳遞層訓練修改之 GraFRank，隱藏維度大小為 64，輸出嵌入維度  $D = 32$ 。在每一層中，我們為每個採樣的一階採樣 15 個一階鄰居和 15 個二階鄰居鄰居；每個用戶接收來自多達 225 個朋友的消息。在模型訓練期間，我們在兩層中都應用了 0.3 的 dropout。使用 Adam 優化器對模型進行最多 30 個 epoch 的訓練，批量大小為 256 個正對（除了每對 5 個隨機/硬負例）和 0.001 的學習率。

### E. 實驗結果與分析

首先展示實驗的主要結果，改善的模型將 GraFRank 與候選人檢索和排名任務的競爭基線進行比較，結果如表 V-1 所示。

（已經做過很多嘗試，還是沒有做出來）

## VI. 結論

在這次報告的目標是希望可以修改 GraFRank 模型，進而讓此跨模態的模型可以應用在 Snapchat 以外的平台上（如：Facebook），並且能夠解決數據稀疏性的問題。共通點是我要實驗的平台也是 circle 的形式，包含中心使用者以及其相關的用戶連結，然後得到彼此的特徵轉成嵌入向量，進而得到其他使用者與中心使用者的相關性分數，然後做好友推薦。

預期進度是能做出推薦效果差不多的改善之模型，讓預期的數據集能利用 GraFRank 的特性做潛在好友推薦，以及了解 GraFRank 模型的多模態在 Facebook 平台上是

否可以達到有效的應用，然後了解 GNN 延伸之模型在推薦系統上的成效，並且進而比較普遍的模型 LightGCN。

最後的成果只做到把 Facebook 數據集的資料應用到 GraFRank 此模型中，然後產生中心使用者對應的嵌入向量，要如何把完整的結合了鄰居好友、自己以及鄰居好友特徵的資訊進一步做出潛在好友推薦，我在這次報告沒有做出來。

我有歸納出幾項原因導致成果做不出來，第一，參考論文之模型方法的多模態是以時間為單位分為多個群組，然後對多個群組進行多模態的注意力機制融合，最後產出一個三維的嵌入向量，分別是使用者的潛在使用者 output、正向使用者、負向使用者，但我所使用的資料集原本預計是把時間便向轉成群組（如圖 II-1 呈現，一中心使用的好友可區分為不同的群組，例如：高中朋友、家人等等），在不同的嵌入向量下，其中的維度需要再做調整，但我直接整個嵌入放進去，造成產出的向量不同，應該要對 output 的維度依照我自己的數據及下去做詮釋；第二，參考論文之 GraFRank 方法包含多個使用者的背景資訊（包含與好友的互動、交流資訊興趣等），而我所使用的資料集只包含了中心使用者以及有相關之好友使用者的特徵，在缺少很多額外背景資訊的情況下，可能也是造成模型無法有效運作的原因；最後，在有些 Pytorch 的使用還不太熟悉的情況下，可能有很多我可以利用的工具，但是因為不了解，沒辦法很好的應用在程式上面。

但即便沒有做出跑出結果，我覺得這次報告還是有很多值得自己參考的地方，因為有整體寫出在這篇報告希望做到的目標、方法之應用、公式的應用、每一個變數的意義，讓我更知道整體的架構，以及在實作過程遇到的問題出在哪邊，更知道這個報告在做什麼事情，想解決的問題是什麼等等，因為一開始我對於問題的定義非常模糊，寫了程式也不知道每一個步驟的實際意義，單純把資料匯入到程式裡是沒有意義的，如果不能了解每一變數、模型架構、層數、輸出的向量代表什麼，沒辦法進行下一步的動作。

後續或許可以嘗試先應用在 LightGCN 上面，透過 LightGCN 將此資料集做潛在好友推薦，然後把 GraFRank 的概念運用到 GCN 上，看推薦效果是否有提升。

最後在這次報告我發現很重要的是在一開始訂題目，預期達到甚麼目標、想解決甚麼問題、預期用甚麼方法等等必須非常清楚，一開始模稜兩可如果方向不對不清

楚到後面會很難做，雖然沒有跑出成果，但這次的報告經驗對我在未來的論文書寫以及實驗方面有很大的幫助。

#### REFERENCES

- Chen, L., Xie, Y., Zheng, Z., Zheng, H., & Xie, J. (2020). Friend Recommendation Based on Multi-Social Graph Convolutional Network. *IEEE Access*, 8, 43618-43629.  
<https://doi.org/10.1109/ACCESS.2020.2977407>
- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). Lightgcn: Simplifying and powering graph convolution network for recommendation. Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval,
- Huang, S., Zhang, J., Wang, L., & Hua, X. S. (2016). Social Friend Recommendation Based on Multiple Network Correlation. *IEEE Transactions on Multimedia*, 18(2), 287-299.  
<https://doi.org/10.1109/TMM.2015.2510333>
- Liben-Nowell, D., & Kleinberg, J. (2003). *The link prediction problem for social networks* Proceedings of the twelfth international conference on Information and knowledge management, New Orleans, LA, USA.  
<https://doi.org/10.1145/956863.956972>
- Liu, Y., Yang, H., Sun, G., & Bin, S. (2020). Collaborative Filtering Recommendation Algorithm Based on Multi-relationship Social Network. *Ingénierie des Systèmes d'Information*, 25(3).
- Ma, H., Yang, H., Lyu, M. R., & King, I. (2008). *SoRec: social recommendation using probabilistic matrix factorization* Proceedings of the 17th ACM conference on Information and knowledge management, Napa Valley, California, USA.  
<https://doi.org/10.1145/1458082.1458205>
- Peng, D., Yuan, W., & Liu, C. (2019). HARSAM: A Hybrid Model for Recommendation Supported by Self-Attention Mechanism. *IEEE Access*, 7, 12620-12629.  
<https://doi.org/10.1109/ACCESS.2019.2892565>
- Sankar, A., Liu, Y., Yu, J., & Shah, N. (2021). *Graph Neural Networks for Friend Ranking in Large-scale Social Platforms* Proceedings of the Web Conference 2021, Ljubljana, Slovenia.  
<https://doi.org/10.1145/3442381.3450120>
- Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C., & Philip, S. Y. (2020). A comprehensive survey on graph neural networks. *IEEE transactions on neural networks and learning systems*, 32(1), 4-24.
- Yang, B., Lei, Y., Liu, J., & Li, W. (2017). Social Collaborative Filtering by Trust. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(8), 1633-1647.  
<https://doi.org/10.1109/TPAMI.2016.2605085>
- Yi, H., Liu, J., Xu, W., Li, X., & Qian, H. (2023). A Graph Neural Network Social Recommendation Algorithm Integrating the Multi-Head Attention Mechanism. *Electronics*, 12(6), 1477.  
<https://www.mdpi.com/2079-9292/12/6/1477>
- Yu, Z., Lian, J., Mahmood, A., Liu, G., & Xie, X. (2019). Adaptive user modeling with long and short-term preferences for personalized recommendation Proceedings of the 28th International Joint Conference on Artificial Intelligence, Macao, China